

BÁO CÁO THỰC HÀNH: GPU FINOPS & TỐI ƯU HÓA CHI PHÍ

Sinh viên: Phạm Minh Khôi

MSSV: 2A202600262

Ngày báo cáo: 13/05/2026

1. GIỚI THIỆU

Báo cáo này trình bày kết quả thực hiện bài Lab về GPU FinOps, tập trung vào việc quản lý, giám sát và tối ưu hóa chi phí vận hành các cụm GPU dành cho AI/ML. Mục tiêu chính là làm quen với các khái niệm cốt lõi như tracking chi phí (OpenCost-like), tự động mở rộng (Autoscaling), quản lý Spot Instances và tối ưu hóa hiệu năng huấn luyện thông qua Mixed Precision (AMP).

2. PHÂN TÍCH HỆ THỐNG MÔ PHỎNG (PART 1-7)

Hệ thống mô phỏng (Mock Cluster) cung cấp cái nhìn toàn diện về cơ chế vận hành của một nền tảng Cloud nội bộ.

- Giám sát cụm (Cluster Monitoring):** Trạng thái khởi tạo cho thấy cụm có 8 GPU trên 4 nodes với mức sử dụng trung bình ban đầu rất thấp (6.5%), dẫn đến lãng phí tài nguyên nhân rồi đáng kể.
- Quản lý Spot Instance:** Thông qua mô phỏng, việc sử dụng Spot Instance đã chứng minh hiệu quả kinh tế vượt trội với mức tiết kiệm lên tới **70%** so với giá On-demand. Mặc dù có sự kiện thu hồi (preemption) xảy ra (như instance `spot-t4-002` bị thu hồi sau 9 giây), hệ thống vẫn bảo vệ được lợi ích về chi phí.
- Phân tích lãng phí (Waste Analysis):** Báo cáo ghi nhận tỷ lệ lãng phí trung bình là **23.2%** (Severity: LOW). Tiềm năng tiết kiệm hàng tháng dự kiến lên đến **\$2,289.51** nếu thực hiện các khuyến nghị tối ưu như Right-sizing hoặc Scale-down các GPU nhàn rỗi.

3. PHÂN TÍCH HUẤN LUYỆN TRÊN GPU THẬT (PART 8)

Thực hiện huấn luyện mô hình ResNet-18 trên tập dữ liệu CIFAR-10 sử dụng GPU thật từ nền tảng Kaggle. Kết quả so sánh giữa chế độ FP32 (truyền thống) và AMP (Mixed Precision) cho thấy sự chênh lệch rõ rệt:

Chỉ số	FP32 (Baseline)	AMP (Optimized)	Cải thiện
Tổng thời gian	123.9 giây	61.9 giây	2.00x nhanh hơn

Bộ nhớ đỉnh	0.82 GB	0.60 GB	Tiết kiệm 0.22 GB
Chi phí (USD)	\$0.012044	\$0.006016	Tiết kiệm 50.1%

Việc áp dụng Mixed Precision không chỉ rút ngắn một nửa thời gian huấn luyện mà còn giảm trực tiếp 50% chi phí hóa đơn cho cùng một tác vụ.

4. PHÂN TÍCH CHIẾN LƯỢC NÂNG CAO (PART 8.5)

Dựa trên các bài toán mở rộng và dự báo chi phí:

- **Hiệu quả mở rộng (Multi-GPU Scaling):** Phân tích cho thấy khi tăng số lượng GPU, hiệu suất mở rộng giảm dần (từ 100% xuống 70% khi dùng 8 GPU) do chi phí giao tiếp giữa các card. Tuy nhiên, chi phí trên mỗi đơn vị hiệu năng (*cost_per_unit_perf*) giảm từ 7.34 xuống **1.87**, cho thấy việc scale-up vẫn mang lại lợi ích lớn về tốc độ thực hiện dự án.
- **Dự báo ngân sách (Forecasting):** Dự án mẫu được dự báo có tổng chi phí cơ sở là **\$3,551.2**, với quỹ dự phòng 20% mang lại ngân sách đề xuất là **\$4,261.44**. Điều này giúp doanh nghiệp quản trị rủi ro tài chính tốt hơn.
- **Thử thách thiết kế (Challenge Exercise):** Đối với dự án Fine-tuning LLM vượt ngân sách ban đầu (\$5,872), chiến lược kết hợp **AMP và Spot Instances** đã giúp đưa chi phí xuống còn **\$1,324.51** (tiết kiệm **77.4%**). Chiến lược này được đánh giá là an toàn vì thời gian thực hiện (150h) vẫn nằm trong deadline cho phép, ngay cả khi có rủi ro bị thu hồi Spot.

5. KẾT LUẬN

Bài Lab đã cung cấp những kỹ năng thực tiễn về GPU FinOps. Việc kết hợp các kỹ thuật phần mềm (Mixed Precision) với chiến lược hạ tầng (Spot Instances, Autoscaling) là chìa khóa để vận hành các dự án AI hiệu quả về mặt chi phí mà không ảnh hưởng đến tiến độ dự án.